

Estudo de Caso 02: Análise da rentabilidade de ações

Homero Castro, Isaac Marinho e Stéfani Verissimo

12 de outubro de 2025

1. Introdução

O presente relatório detalha uma análise estatística abrangente para avaliar e comparar o desempenho de cinco ativos de renda variável. Utilizando uma série histórica de retornos mensais que abrange um período de 36 meses, o estudo busca entender se existem diferenças estatisticamente significativas no desempenho entre esses ativos e, em caso afirmativo, qual deles apresenta o perfil de risco-retorno mais favorável.

A metodologia empregada vai além de uma simples comparação de médias, adotando uma abordagem multifacetada para garantir a robustez das conclusões. A análise inicia-se com uma avaliação descritiva e visual, incluindo métricas de retorno ajustado ao risco, como o Índice de Sharpe, e gráficos que ilustram a distribuição, evolução temporal e correlação entre os ativos.

O pilar central do estudo é a Análise de Variância (ANOVA), empregada para testar a hipótese nula de igualdade entre os retornos médios. Esta análise inferencial é complementada por testes post-hoc de Tukey, para identificar as fontes específicas de variação, e é rigorosamente validada pela verificação completa das premissas estatísticas de homogeneidade de variâncias, normalidade e independência dos resíduos. Adicionalmente, uma análise de potência foi realizada para contextualizar a sensibilidade dos achados e a força das conclusões, especialmente nos casos onde diferenças não foram estatisticamente significativas.

O objetivo deste documento é, portanto, fornecer uma recomendação de investimento baseada em evidências quantitativas sólidas, detalhando a metodologia, os resultados e as visualizações que levaram aos *insights* necessários para a conclusão final de que a ação com melhor performance e portanto recomendada é a ação 1.

Os códigos implementados para realização do presente estudo de caso estão disponíveis no repositório do github do grupo

2. Metodologia

###2.1 Análise Exploratória de Dados (AED)

Num primeiro momento, foi realizada uma exploração aprofundada dos dados fornecidos acerca do desempenho das ações para extrair estatísticas descritivas, identificar padrões e visualizar as características primárias de cada ativo. Após o carregamento dos preços históricos das ações avaliadas, os retornos mensais de cada uma das cinco ações e da taxa Selic foram calculados e organizados em um formato de dados longos para facilitar a análise e a plotagem.

```
# Carrega os dados da taxa selic dos ultimos 36 meses e calcula os rendimentos mensais
taxas_selic_anuais_historicas <- c(
  rep(0.1365, 12), 0.1315, rep(0.1265, 2), 0.1215, rep(0.1165, 2),
  0.1115, rep(0.1065, 2), rep(0.1040, 3), rep(0.1065, 2), 0.1115,
  0.1215, rep(0.1315, 2), rep(0.1415, 2), 0.1465, rep(0.1490, 2), 0.1500
)
```

```

taxas_selic_mensais_historicas <- (1 + taxas_selic_anuais_historicas)^(1/12) - 1
taxas_selic_mensais_periodo <- taxas_selic_mensais_historicas[2:36]

# Carrega dados e calcula retornos mensais de cada uma das 5 ações

nomes_acoes <- paste0("Acao_", 1:5)
precos_df <- read_csv("DadosAcoesGrupoE.csv", col_names = nomes_acoes, show_col_types = FALSE)
retornos_df <- as.data.frame(sapply(precos_df, function(coluna_preco) {
  (coluna_preco[-length(coluna_preco)] - coluna_preco[-1]) / coluna_preco[-1]
}))

excess_returns_df <- retornos_df - taxas_selic_mensais_periodo
retornos_long_df <- retornos_df %>%
  pivot_longer(cols = everything(), names_to = "Acao", values_to = "Retorno_Bruto") %>%
  mutate(Acao = as.factor(Acao))
excess_returns_long_df <- excess_returns_df %>%
  pivot_longer(cols = everything(), names_to = "Acao", values_to = "Excesso_Retorno")

```

Num segundo momento, métricas como o retorno médio, desvio padrão (como proxy do risco) e o índice de Sharpe para cada uma das ações foram calculadas e visualizações auxiliares como um boxplot da distribuição dos retornos das ações e da taxa selic e um histograma do valor do índice de Sharpe para cada ação em relação à selic foram produzidas. O Índice de Sharpe pode ser calculado de acordo com a seguinte equação:

$$S_a = \frac{E[R_a - R_b]}{\sigma_a}$$

Onde R_a é a taxa de retorno da ação, R_b é a taxa de retorno *benchmark* (selic), $E[R_a - R_b]$ é o valor esperado do excesso do retorno da ação em relação ao retorno *benchmark* e σ_a é o desvio padrão do excesso do retorno da ação em relação ao *benchmark*.

2.2 Definição da Hipótese e Análise Inferencial

Após a análise preliminar descrita, a questão central da análise foi formalizada através de um teste de hipóteses para determinar se as diferenças observadas nos retornos médios eram estatisticamente significativas.

Hipótese Nula (H): Os retornos médios de todas as cinco ações são iguais. ($\mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$)

Hipótese Alternativa (H): O retorno médio de pelo menos uma das ações é diferente das demais.

Para testar essa hipótese, foi utilizada a Análise de Variância (ANOVA) de um fator. Este método foi escolhido por ser a ferramenta padrão para comparar as médias de três ou mais grupos, controlando a taxa de erro familiar que ocorreria com o uso de múltiplos testes t. Uma vez que a ANOVA se mostre significativa (rejeição de H), um teste post-hoc de Tukey HSD (Honest Significant Difference) será realizado para identificar quais pares específicos de ações apresentavam diferenças estatisticamente significativas.

[INSERIR GRÁFICO: INTERVALOS DE CONFIANÇA DO TESTE DE TUKEY]

A figura acima ilustra os resultados do teste post-hoc, mostrando a estimativa da diferença de médias e o intervalo de confiança de 95% para cada par de ações, destacando as comparações classificadas como significativas (p-valor < 0.05) e marginalmente significativas (0.05 < p-valor < 0.1).

As comparações classificadas como significativas foram a 1-2 e 1-4, e a única marginalmente significativa foi a 1-5, todas as outras apresentando um p-valor superior as margens definidas, indicando que não há evidência suficiente para afirmar sua não equivalência estatística.

2.3 Validação das Premissas do Modelo

Por fim, é fato que a validade das conclusões da ANOVA depende de três premissas fundamentais sobre os resíduos do modelo, sendo elas a normalidade, a homocedasticidade e a independência dos resíduos obtidos na ANOVA. Cada premissa foi verificada tanto com um teste estatístico formal quanto com uma inspeção gráfica.

No caso da premissa de que os erros do modelo seguem a distribuição normal, o teste estatístico realizado foi o teste de **Shapiro-Wilk** e a visualização foi realizada por um **Gráfico Normal Quantil-Quantil**. Já a premissa de que a variância dos resíduos é constante entre os grupos foi verificada pelo teste estatístico de **Fligner-Killeen** e visualmente pelo mesmo boxplot da análise descritiva dos dados. Por fim, a premissa de que os erros são independentes (não autocorrelacionados) foi verificada pelo teste estatístico de **Durbin-Watson** e visualmente pelo **Gráfico da Função de Autocorrelação (ACF)** dos resíduos.

3 Resultados e discussão

3.1 Análise Exploratória de Dados (AED)

```
desc_stats <- retornos_long_df %>%
  group_by(Acao) %>%
  summarise(
    Media_Retorno = mean(Retorno_Bruto, na.rm = TRUE),
    Desvio_Padiao = sd(Retorno_Bruto, na.rm = TRUE),
    .groups = 'drop'
  )
mean_excess_returns <- excess_returns_long_df %>%
  group_by(Acao) %>%
  summarise(Media_Excesso_Retorno = mean(Excesso_Retorno, na.rm = TRUE))
desc_stats <- left_join(desc_stats, mean_excess_returns, by = "Acao")
desc_stats <- desc_stats %>%
  mutate(Indice_Sharpe = Media_Excesso_Retorno / Desvio_Padiao)

print(kable(desc_stats, "pipe", digits = 4, caption = "Estatísticas Descritivas (Sharpe com Selic Históricas)"))
```

3.1.1 Estatísticas Descritivas:

```
##
##
## Table: Estatísticas Descritivas (Sharpe com Selic Histórica)
##
## | Acao | Media_Retorno | Desvio_Padiao | Media_Excesso_Retorno | Indice_Sharpe |
## |:-----|:-----|:-----|:-----|:-----|
## | Acao_1 | 0.0134 | 0.0093 | 0.0034 | 0.3621 |
## | Acao_2 | 0.0043 | 0.0086 | -0.0057 | -0.6607 |
## | Acao_3 | 0.0083 | 0.0097 | -0.0017 | -0.1753 |
## | Acao_4 | 0.0025 | 0.0118 | -0.0076 | -0.6423 |
## | Acao_5 | 0.0071 | 0.0106 | -0.0030 | -0.2798 |
```

```

# PASSO 1: Criar um data frame para os retornos da Selic
# As colunas devem ter os mesmos nomes do data frame dos retornos das ações ('Acao', 'Retorno_Bruto')
selic_df <- data.frame(
  Acao = "Selic",
  Retorno_Bruto = taxas_selic_mensais_perodo
)

# PASSO 2: Unir os data frames das ações e da Selic
df_combinado <- rbind(retornos_long_df, selic_df)

# PASSO 3: Definir a ordem das categorias no eixo X para melhor visualização
# Colocamos a Selic primeiro para servir como benchmark de referência
df_combinado$Acao <- factor(df_combinado$Acao, levels = c("Selic", "Acao_1", "Acao_2", "Acao_3", "Acao_4", "Acao_5"))

# PASSO 4: Gerar o boxplot aprimorado
# Usaremos scale_fill_manual() para dar uma cor distinta à Selic
boxplot_comparativo <- ggplot(df_combinado, aes(x = Acao, y = Retorno_Bruto, fill = Acao)) +
  geom_boxplot() +
  geom_hline(yintercept = 0, linetype = "dashed", color = "black") + # Linha de referência no zero

# Define uma paleta de cores manual para destacar a Selic
scale_fill_manual(
  name = "Ativo",
  values = c(
    "Selic" = "skyblue",
    "Acao_1" = "gray80",
    "Acao_2" = "gray80",
    "Acao_3" = "gray80",
    "Acao_4" = "gray80",
    "Acao_5" = "gray80"
  )
) +

labs(
  title = "Distribuição dos Retornos Mensais: Ações vs. Selic",
  subtitle = "Período de análise: 2022-2025",
  x = "Ativo",
  y = "Retorno Bruto Mensal"
) +
theme_minimal() +
theme(legend.position = "none") # Remove a legenda, pois a distinção de cores é clara

print(boxplot_comparativo)

```

3.1.2 Distribuição dos Retornos A figura 1 ilustra a comparação visual da distribuição dos retornos mensais de cada ação contra o benchmark da Selic. Nela, é possível notar que o tamanho das caixas de cada uma das ações é distinto, indicativo de que pode haver certa heterogeneidade nas variâncias observadas nas ações. Além disso, fica claro que apenas a ação 1 apresenta uma mediana superior à mediana da taxa selic, sendo uma possível evidência de desempenho superior às demais ações.




Figure 1: Boxplot da distribuição dos retornos das ações e da taxa selic.

```

# Gráfico de barras para comparar o Índice de Sharpe
# Usamos reorder(Acao, -Indice_Sharpe) para ordenar as barras da maior para a menor
barchart_sharpe <- ggplot(desc_stats, aes(x = reorder(Acao, -Indice_Sharpe), y = Indice_Sharpe, fill = Acao)) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = round(Indice_Sharpe, 2)), vjust = ifelse(desc_stats$Indice_Sharpe > 0, 1.5, -0.5)) +
  labs(
    title = "Comparação do Índice de Sharpe por Ação",
    subtitle = "Maior valor indica melhor retorno ajustado ao risco",
    x = "Ação",
    y = "Índice de Sharpe"
  ) +
  theme_minimal() +
  theme(legend.position = "none")

print(barchart_sharpe)

```




Figure 2: Histograma do valor do índice de Sharpe de cada ação em relação a selic.

3.1.3 Desempenho Ajustado ao Risco A figura 2 resume visualmente a conclusão da análise de desempenho, destacando a ação 1 como único ativo com performance positiva ajustada ao risco, corroborando com as inferências tomadas com base no boxplot.

3.2 ANOVA e teste post-hoc TUKEY-HSD

```
retornos_long_df_para_teste <- retornos_long_df %>% rename(Retorno = Retorno_Bruto)

anova_result <- aov(Retorno ~ Acao, data = retornos_long_df_para_teste)
anova_result <- aov(Retorno ~ Acao, data = retornos_long_df_para_teste)
print(summary(anova_result))
```

```
##              Df    Sum Sq   Mean Sq F value    Pr(>F)
## Acao           4 0.002462 0.0006155    6.092 0.000132 ***
## Residuals    170 0.017175 0.0001010
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
p_valor_anova <- summary(anova_result)[[1]][["Pr(>F)"]][1]
```

```
tukey_glht <- glht(anova_result, linfct = mcp(Acao = "Tukey"))
summary(tukey_glht)
```

```
##
## Simultaneous Tests for General Linear Hypotheses
##
## Multiple Comparisons of Means: Tukey Contrasts
##
##
## Fit: aov(formula = Retorno ~ Acao, data = retornos_long_df_para_teste)
##
## Linear Hypotheses:
##              Estimate Std. Error t value Pr(>|t|)
## Acao_2 - Acao_1 == 0 -0.009067   0.002403  -3.774 0.002000 **
## Acao_3 - Acao_1 == 0 -0.005054   0.002403  -2.104 0.223335
## Acao_4 - Acao_1 == 0 -0.010931   0.002403  -4.549 0.000118 ***
## Acao_5 - Acao_1 == 0 -0.006316   0.002403  -2.629 0.069739 .
## Acao_3 - Acao_2 == 0  0.004013   0.002403   1.670 0.455268
## Acao_4 - Acao_2 == 0 -0.001864   0.002403  -0.776 0.937286
## Acao_5 - Acao_2 == 0  0.002751   0.002403   1.145 0.782398
## Acao_4 - Acao_3 == 0 -0.005876   0.002403  -2.446 0.108397
## Acao_5 - Acao_3 == 0 -0.001262   0.002403  -0.525 0.984692
## Acao_5 - Acao_4 == 0  0.004615   0.002403   1.921 0.310458
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## (Adjusted p values reported -- single-step method)
```

```
tukey_CI <- confint(tukey_glht, level = 0.95)
sig <- c("Acao_2 - Acao_1", "Acao_4 - Acao_1")
marginal <- "Acao_5 - Acao_1"
CI_plot <- plot_tukey_CI(
  tukey_confint_obj = tukey_CI,
  comp_significativas = sig,
  comp_marginais = marginal
)
```

```
## Warning: `geom_errorbarh()` was deprecated in ggplot2 4.0.0.
## i Please use the `orientation` argument of `geom_errorbar()` instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.

## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## i The deprecated feature was likely used in the ggplot2 package.
## Please report the issue at <https://github.com/tidyverse/ggplot2/issues>.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

```
print(CI_plot)
```

```
## `height` was translated to `width`.
```




Figure 3: Intervalos de confiança do teste post-hoc Tukey-HSD.

A figura 3 ilustra os resultados do teste post-hoc, mostrando a estimativa da diferença de médias e o intervalo de confiança de 95% para cada par de ações, destacando as comparações classificadas como significativas ($p\text{-valor} \leq 0.05$) e marginalmente significativas ($0.05 < p\text{-valor} \leq 0.1$).

As comparações classificadas como significativas foram a 1-2 e 1-4, e a única marginalmente significativa foi a 1-5, todas as outras apresentando um p-valor superior as margens definidas, indicando que não há evidência suficiente para afirmar sua não equivalência estatística.

3.3 Validação das Premissas do Modelo

```
residuos <- residuals(anova_result)
shapiro_results <- shapiro.test(residuos)
print(shapiro_results)
```

3.3.1 Normalidade dos Resíduos

```
##
## Shapiro-Wilk normality test
##
## data:  residuos
## W = 0.98985, p-value = 0.2469
```

```
qqPlot(residuos,
  main = "Gráfico Q-Q", # Título principal
  xlab = "Quantis Teóricos da Distribuição Normal", # Legenda do eixo X
  ylab = "Resíduos do Modelo", # Legenda do eixo Y
  pch = 16,
  lwd = 2, # Um pouco menos espesso que antes para equilibrar
  cex = 1.5 # Um pouco menor para um visual mais limpo
)
```

```
## [1] 5 112
```

A figura 4 ilustra visualmente o alinhamento dos resíduos com uma distribuição normal teórica, evidenciando sua normalidade, evidenciada também pelo p-valor elevado (0.2469) obtido no teste de Shapiro-Wilk realizado.

```
fligner_test_result <- fligner.test(Retorno ~ Acao, data = retornos_long_df_para_teste)
print(fligner_test_result)
```

2.3.2 Homogeneidade de Variâncias (Homocedasticidade)

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data:  Retorno by Acao
## Fligner-Killeen:med chi-squared = 6.0758, df = 4, p-value = 0.1936
```

O teste de *Fligner-Killeen* realizado retornou um p-valor de 0.1936, que não rejeita a hipótese nula de que as variâncias dos resíduos são iguais, o que contrasta com o observado no boxplot da figura 1, que demonstra certa discrepância no tamanho das caixas de cada uma das ações. Para os fins do presente estudo de caso, a premissa foi considerada satisfeita, uma vez que o teste estatístico é mais confiável que uma análise gráfica.




Figure 4: Gráfico Q-Q para verificação da premissa de normalidade dos resíduos do modelo ANOVA.

```
durbin_watson_result <- car::durbinWatsonTest(anova_result)
print(durbin_watson_result)
```

3.3.3 Independência dos Resíduos

```
## lag Autocorrelation D-W Statistic p-value
## 1 0.09164938 1.807413 0.244
## Alternative hypothesis: rho != 0
```

```
acf(residuos, main = "Função de Autocorrelação dos Resíduos da ANOVA")
```




Figure 5: Gráfico da Função de Autocorrelação (ACF) dos resíduos do modelo ANOVA

O teste de **Durbin-Watson** realizado obteve um p-valor de 0.274, que não é suficiente para rejeitar a hipótese nula de que não há autocorrelação entre os resíduos, ou seja, os resultados do teste evidenciam a independência dos dados.

Além disso, a figura 5 mostra que não há correlações significativas nos resíduos na maior parte das diferentes defasagens temporais, suportando a premissa de independência. A única defasagem que apresentou correlação significativa foi a de 7 meses.

Considerando a natureza dos dados, o esperado caso de fato houvesse autocorrelação é que esta ocorresse em baixas defasagens (1, 2 ou 3 meses), uma vez que indicam efeitos de curto prazo como “momentum” ou “reversão à média”. Além disso, a força da correlação é baixa, superando por muito pouco o *threshold* de

5%, o que aliado ao efeito esperado da aleatoriedade de que pelo menos 1 a cada 20 observações em séries perfeitamente aleatórias supere a *threshold* de significância de 5% suporta a conclusão que a significância observada nesta defasagem é fruto de aleatoriedade e não representa autocorrelação real.

4. Conclusões

Apendice A - Funções dos integrantes

- Isaac: Responsável pelo projeto e implementação do estudo de caso, esboçar o relatório e discutir a realização do estudo, bem como seus resultados;
- Stéfani: Responsável por discutir a realização do estudo, bem como seus resultados, redigir o texto completo completando e incrementando o esboço;
- Homero: Responsável por discutir a realização do estudo, bem como seus resultados, revisar e complementar o relatório e redigir a versão final.