

Estudo de Caso 02: Análise da rentabilidade de ações

Homero Castro, Isaac Marinho e Stéfani Verissimo

13 de outubro de 2025

Resumo

O presente relatório detalha uma análise estatística abrangente para avaliar e comparar o desempenho de cinco ativos de renda variável. Utilizando uma série histórica de retornos mensais que abrange um período de 36 meses, o estudo busca entender, por meio de testes de hipóteses, se existem diferenças estatisticamente significativas no desempenho entre esses ativos e, em caso afirmativo, qual deles apresenta o perfil de risco-retorno mais favorável.

1. Introdução

Neste estudo de caso, é considerado um cenário no qual um investidor deseja investir seu montante financeiro integralmente em uma ação, de forma a garantir a maior rentabilidade mensal possível. Para essa decisão, foram selecionadas cinco ações e coletados os preços de fechamento dessas ações ao longo de 36 meses. O propósito do trabalho é determinar, a partir desses dados coletados e por meio de ferramentas estatísticas, qual dessas ações apresenta maior potencial.

A metodologia empregada vai além de uma simples comparação de médias, adotando uma abordagem multifacetada para garantir a robustez das conclusões. A análise inicia-se com uma avaliação descritiva e visual, incluindo métricas de retorno ajustado ao risco, como o Índice de Sharpe, e gráficos que ilustram a distribuição, evolução temporal e correlação entre os ativos.

O pilar central do estudo é a Análise de Variância (ANOVA), empregada para testar a hipótese nula de igualdade entre os retornos médios. Essa análise inferencial é complementada por testes *post hoc* de Tukey, para identificar as fontes específicas de variação, e é rigorosamente validada pela verificação completa das premissas estatísticas de homogeneidade de variâncias, normalidade e independência dos resíduos. Adicionalmente, uma análise do poder foi realizada para contextualizar a sensibilidade dos achados e a força das conclusões, especialmente nos casos onde diferenças não foram estatisticamente significativas.

O objetivo deste documento é, portanto, fornecer uma recomendação de investimento baseada em evidências quantitativas sólidas, detalhando a metodologia, os resultados e as visualizações que levaram aos *insights* necessários para a conclusão final.

Os códigos implementados para realização do presente estudo de caso estão disponíveis no repositório do GitHub do grupo.

2. Metodologia

2.1 Análise Exploratória de Dados (AED)

Em um primeiro momento, foi realizada uma exploração aprofundada dos dados fornecidos acerca do desempenho das ações para extrair estatísticas descritivas, identificar padrões e visualizar as características primárias de cada ativo. Após o carregamento dos preços históricos das ações avaliadas, os retornos mensais de cada uma das cinco ações e da taxa Selic foram calculados e organizados em um formato de dados longos para facilitar a análise e a plotagem.

```

# Carrega os dados da taxa selic dos ultimos 36 meses e calcula os rendimentos mensais
taxas_selic_anuais_historicas <- c(
  rep(0.1365, 12), 0.1315, rep(0.1265, 2), 0.1215, rep(0.1165, 2),
  0.1115, rep(0.1065, 2), rep(0.1040, 3), rep(0.1065, 2), 0.1115,
  0.1215, rep(0.1315, 2), rep(0.1415, 2), 0.1465, rep(0.1490, 2), 0.1500
)

taxas_selic_mensais_historicas <- (1 + taxas_selic_anuais_historicas)^(1/12) - 1
taxas_selic_mensais_periodo <- taxas_selic_mensais_historicas[2:36]

# Carrega dados e calcula retornos mensais de cada uma das 5 ações

nomes_acoes <- paste0("Acao_", 1:5)
precos_df <- read_csv("DadosAcoesGrupoE.csv", col_names = nomes_acoes,
  show_col_types = FALSE)
retornos_df <- as.data.frame(sapply(precos_df, function(coluna_preco) {
  (coluna_preco[-length(coluna_preco)] - coluna_preco[-1]) / coluna_preco[-1]
}))

excess_returns_df <- retornos_df - taxas_selic_mensais_periodo
retornos_long_df <- retornos_df %>%
  pivot_longer(cols = everything(), names_to = "Acao", values_to = "Retorno_Bruto") %>%
  mutate(Acao = as.factor(Acao))
excess_returns_long_df <- excess_returns_df %>%
  pivot_longer(cols = everything(), names_to = "Acao", values_to = "Excesso_Retorno")

```

Na próxima subseção, métricas como o retorno médio, devio padrão (como proxy do risco) e o índice de Sharpe para cada uma das ações foram calculadas e visualizações auxiliares como um boxplot da distribuição dos retornos das ações e da taxa selic e um histograma do valor do índice de Sharpe para cada ação em relação à selic foram produzidas. O Índice de Sharpe pode ser calculado de acordo com a seguinte equação:

$$S_a = \frac{E[R_a - R_b]}{\sigma_a}$$

Onde R_a é a taxa de retorno da ação, R_b é a taxa de retorno *benchmark* (selic), $E[R_a - R_b]$ é o valor esperado do excesso do retorno da ação em relação ao retorno *benchmark* e σ_a é o desvio padrão do excesso do retorno da ação em relação ao *benchmark*.

2.2 Definição da Hipótese e Análise Inferencial

Após a análise preliminar descrita, a questão central da análise foi formalizada através de um teste de hipóteses para determinar se as diferenças observadas nos retornos médios eram estatisticamente significativas.

Hipótese Nula (H_0): Os retornos médios de todas as cinco ações são iguais. ($\mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$)

Hipótese Alternativa (H_1): O retorno médio de pelo menos uma das ações é diferente das demais.

Para testar essa hipótese, foi utilizada a Análise de Variância (ANOVA) de um fator. Este método foi escolhido por ser a ferramenta padrão para comparar as médias de três ou mais grupos, controlando a taxa de erro familiar que ocorreria com o uso de múltiplos testes t. Uma vez que a ANOVA se mostre significativa (rejeição de H_0), um teste *post hoc* de Tukey HSD (Honest Significant Difference) será realizado para identificar quais pares específicos de ações apresentavam diferenças estatisticamente significativas.

Durante todo o estudo de caso, foi utilizado um nível de confiança de 95%, ou seja, foi adotado um $\alpha = 0.05$. Por fim, para avaliar a relevância prática dos resultados, foi encontrado o tamanho do efeito por meio do cálculo do poder do teste ANOVA realizado, considerando um delta equivalente a 1 desvio padrão.

2.3 Validação das Premissas do Modelo

É fato que a validade das conclusões da ANOVA depende de três premissas fundamentais sobre os resíduos do modelo, sendo elas a normalidade, a homocedasticidade e a independência dos resíduos obtidos na ANOVA. Cada premissa foi verificada tanto com um teste estatístico formal quanto com uma inspeção gráfica.

No caso da premissa de que os resíduos do modelo seguem a distribuição normal, o teste estatístico realizado foi o teste de **Shapiro-Wilk** e a visualização foi realizada por um **Gráfico Normal Quantil-Quantil**. Já a premissa de que a variância dos resíduos é constante entre os grupos foi verificada pelo teste estatístico de **Fligner-Killeen** e visualmente pelo mesmo boxplot da análise descritiva dos dados. Por fim, a premissa de que os erros são independentes (não autocorrelacionados) foi verificada pelo teste estatístico de **Durbin-Watson** e visualmente pelo **Gráfico da Função de Autocorrelação (ACF)** dos resíduos.

3 Resultados e discussão

3.1 Análise Exploratória de Dados (AED)

3.1.1 Estatísticas Descritivas: As estatísticas descritivas dos dados foram calculadas da seguinte maneira:

```
desc_stats <- retornos_long_df %>%
  group_by(Acao) %>%
  summarise(
    Media_Retorno = mean(Retorno_Bruto, na.rm = TRUE),
    Desvio_Padiao = sd(Retorno_Bruto, na.rm = TRUE),
    .groups = 'drop'
  )
mean_excess_returns <- excess_returns_long_df %>%
  group_by(Acao) %>%
  summarise(Media_Excesso_Retorno = mean(Excesso_Retorno, na.rm = TRUE))
desc_stats <- left_join(desc_stats, mean_excess_returns, by = "Acao")
desc_stats <- desc_stats %>%
  mutate(Indice_Sharpe = Media_Excesso_Retorno / Desvio_Padiao)

print(kable(desc_stats, "pipe", digits = 4,
             caption = "Estatísticas Descritivas (Sharpe com Selic Histórica)"))
```

```
##
##
## Table: Estatísticas Descritivas (Sharpe com Selic Histórica)
##
## | Acao | Media_Retorno | Desvio_Padiao | Media_Excesso_Retorno | Indice_Sharpe |
## | :----- | :----- | :----- | :----- | :----- |
## | Acao_1 | 0.0134 | 0.0093 | 0.0034 | 0.3621 |
## | Acao_2 | 0.0043 | 0.0086 | -0.0057 | -0.6607 |
## | Acao_3 | 0.0083 | 0.0097 | -0.0017 | -0.1753 |
## | Acao_4 | 0.0025 | 0.0118 | -0.0076 | -0.6423 |
## | Acao_5 | 0.0071 | 0.0106 | -0.0030 | -0.2798 |
```

3.1.2 Distribuição dos Retornos Para a análise gráfica da distribuição dos retornos foi gerado o boxplot:

```
# PASSO 1: Criar um data frame para os retornos da Selic
# As colunas devem ter os mesmos nomes do data frame dos retornos das ações ('Acao',
# 'Retorno_Bruto')
selic_df <- data.frame(
  Acao = "Selic",
  Retorno_Bruto = taxas_selic_mensais_periodo
```

```

)

# PASSO 2: Unir os data frames das ações e da Selic
df_combinado <- rbind(retornos_long_df, selic_df)

# PASSO 3: Definir a ordem das categorias no eixo X para melhor visualização
# Colocamos a Selic primeiro para servir como benchmark de referência
df_combinado$Acao <- factor(df_combinado$Acao, levels = c("Selic", "Acao_1", "Acao_2",
                                                         "Acao_3", "Acao_4", "Acao_5"))

# PASSO 4: Gerar o boxplot aprimorado
# Usaremos scale_fill_manual() para dar uma cor distinta à Selic
boxplot_comparativo <- ggplot(df_combinado, aes(x = Acao, y = Retorno_Bruto,
                                                fill = Acao)) +

  geom_boxplot() +
  geom_hline(yintercept = 0, linetype = "dashed", color = "black") + # Linha de
  # referência no zero

  # Define uma paleta de cores manual para destacar a Selic
  scale_fill_manual(
    name = "Ativo",
    values = c(
      "Selic" = "skyblue",
      "Acao_1" = "gray80",
      "Acao_2" = "gray80",
      "Acao_3" = "gray80",
      "Acao_4" = "gray80",
      "Acao_5" = "gray80"
    )
  ) +

  labs(
    title = "Distribuição dos Retornos Mensais: Ações vs. Selic",
    subtitle = "Período de análise: 2022-2025",
    x = "Ativo",
    y = "Retorno Bruto Mensal"
  ) +
  theme_minimal() +
  theme(legend.position = "none") # Remove a legenda, pois a distinção de cores é clara

print(boxplot_comparativo)

```

A Figura 1 ilustra a comparação visual da distribuição dos retornos mensais de cada ação contra o benchmark da Selic. Nela, é possível notar que o tamanho das caixas de cada uma das ações é distinto, indicativo de que pode haver certa heterogeneidade nas variâncias observadas nas ações. Além disso, fica claro que apenas a Ação 1 apresenta uma mediana superior à mediana da taxa selic, sendo essa, uma possível evidência de desempenho superior às demais ações.

3.1.3 Desempenho Ajustado ao Risco Para análise gráfica dos desempenhos ajustados, foi gerado o gráfico de barras:

```

# Gráfico de barras para comparar o Índice de Sharpe
# Usamos reorder(Acao, -Indice_Sharpe) para ordenar as barras da maior para a menor
barchart_sharpe <- ggplot(desc_stats, aes(x = reorder(Acao, -Indice_Sharpe),

```




Figure 1: Boxplot da distribuição dos retornos das ações e da taxa selic.

```

y = Indice_Sharpe, fill = Acao)) +
geom_bar(stat = "identity") +
geom_text(aes(label = round(Indice_Sharpe, 2)),
          vjust = ifelse(desc_stats$Indice_Sharpe > 0, 1.5, -0.5)) + # Adiciona o rótulo do valor
labs(
  title = "Comparação do Índice de Sharpe por Ação",
  subtitle = "Maior valor indica melhor retorno ajustado ao risco",
  x = "Ação",
  y = "Índice de Sharpe"
) +
theme_minimal() +
theme(legend.position = "none")

print(barchart_sharpe)

```




Figure 2: Histograma do valor do índice de Sharpe de cada ação em relação a selic.

A Figura 2 resume visualmente a conclusão da análise de desempenho, destacando a Ação 1 como único ativo com performance positiva ajustada ao risco, corroborando com as evidências tomadas com base no boxplot.

3.2 ANOVA e teste *post hoc* TUKEY-HSD

```

retornos_long_df_para_teste <- retornos_long_df %>% rename(Retorno = Retorno_Bruto)
anova_result <- aov(Retorno ~ Acao, data = retornos_long_df_para_teste)

```

```
anova_result <- aov(Retorno ~ Acao, data = retornos_long_df_para_teste)
print(summary(anova_result))
```

```
##              Df    Sum Sq   Mean Sq F value   Pr(>F)
## Acao          4 0.002462 0.0006155    6.092 0.000132 ***
## Residuals    170 0.017175 0.0001010
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
p_valor_anova <- summary(anova_result)[[1]][["Pr(>F)"]][1]
```

O teste ANOVA resultou em um $p\text{-valor} \leq \alpha$, ou seja, a hipótese nula é rejeitada com 95% de confiança. Esse resultado implica que há evidências suficientes para concluirmos que há diferença significativa da média de pelo menos uma ação. Com essa conclusão, faz-se necessário o teste *post hoc* Tukey, que realiza múltiplas comparações para avaliar quais ações diferem entre si. Para esse teste, a hipótese nula é que a média da Ação x é igual a média da Ação y . A hipótese alternativa implica em diferença significativa entre as médias.

```
tukey_glht <- glht(anova_result, linfct = mcp(Acao = "Tukey"))
summary(tukey_glht)
```

```
##
## Simultaneous Tests for General Linear Hypotheses
##
## Multiple Comparisons of Means: Tukey Contrasts
##
##
## Fit: aov(formula = Retorno ~ Acao, data = retornos_long_df_para_teste)
##
## Linear Hypotheses:
##              Estimate Std. Error t value Pr(>|t|)
## Acao_2 - Acao_1 == 0 -0.009067   0.002403  -3.774 0.00202 **
## Acao_3 - Acao_1 == 0 -0.005054   0.002403  -2.104 0.22340
## Acao_4 - Acao_1 == 0 -0.010931   0.002403  -4.549 < 0.001 ***
## Acao_5 - Acao_1 == 0 -0.006316   0.002403  -2.629 0.06962 .
## Acao_3 - Acao_2 == 0  0.004013   0.002403   1.670 0.45526
## Acao_4 - Acao_2 == 0 -0.001864   0.002403  -0.776 0.93728
## Acao_5 - Acao_2 == 0  0.002751   0.002403   1.145 0.78239
## Acao_4 - Acao_3 == 0 -0.005876   0.002403  -2.446 0.10840
## Acao_5 - Acao_3 == 0 -0.001262   0.002403  -0.525 0.98469
## Acao_5 - Acao_4 == 0  0.004615   0.002403   1.921 0.31041
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## (Adjusted p values reported -- single-step method)
```

Analisando os p-valores da tabela acima, observa-se que as comparações entre Ação 1 e Ação 2, e entre Ação 1 e Ação 4, resultaram em valores abaixo de α , o que implica em diferenças estatisticamente significativas. Além disso, a comparação entre as ações 1 e 5 apresentou tendência a diferença, apesar de não ser significativa ao valor de α determinado para o teste. Com base nas diferenças estimadas retornadas pelo teste, podemos ainda concluir que a média estimada da Ação 1 é maior que média estimada das ações 2 e 4. Podemos então esboçar os intervalos de confiança do teste de Tukey.

```
tukey_CI <- confint(tukey_glht, level = 0.95)
sig <- c("Acao_2 - Acao_1", "Acao_4 - Acao_1")
marginal <- "Acao_5 - Acao_1"
CI_plot <- plot_tukey_CI(
  tukey_confint_obj = tukey_CI,
```

```
comp_significativas = sig,
comp_marginais = marginal
)
```

```
## Warning: `geom_errobah()` was deprecated in ggplot2 4.0.0.
## i Please use the `orientation` argument of `geom_errorbar()` instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.

## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## i The deprecated feature was likely used in the ggplot2 package.
## Please report the issue at <https://github.com/tidyverse/ggplot2/issues>.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

```
print(CI_plot)
```

```
## `height` was translated to `width`.
```




Figure 3: Intervalos de confiança do teste *post hoc* Tukey-HSD.

A Figura 3 ilustra os resultados do teste *post hoc*, mostrando a estimativa das diferenças entre médias e os intervalos de confiança de 95% para cada par de ações, destacando as comparações classificadas como significativamente diferentes ($p - valor \leq 0.05$) e marginalmente diferentes ($0.05 \leq p - valor \leq 0.1$). É

importante destacar que os intervalos de confiança que contêm o valor zero, indicam evidências de diferença nula entre as médias comparadas.

Com exceção das comparações classificadas como significativamente diferentes (1-2, 1-4) ou marginalmente diferentes (1-5), as demais comparações apresentaram p-valor superior às margens definidas, indicando que não há evidência suficiente para rejeitar a hipótese de equivalência estatística entre as médias.

3.3 Validação das Premissas do Modelo

Para garantir a correta aplicação do teste de hipóteses por meio do ANOVA e o *post hoc* de Tukey, é necessário testar as premissas de normalidade e independência dos resíduos, bem como a homocedasticidade das variâncias.

3.3.1 Normalidade dos Resíduos

Testamos a normalidade dos resíduos pelo teste de **Shapiro-Wilk**.

```
residuos <- residuals(anova_result)
shapiro_results <- shapiro.test(residuos)
print(shapiro_results)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuos
## W = 0.98985, p-value = 0.2469
```

O teste aplicado aos resíduos resultou em p-valor superior ao nível de significância adotado ($\alpha = 0.05$). Dessa forma, não se rejeita a hipótese nula de normalidade, concluindo-se que os resíduos apresentam distribuição compatível com a normalidade.

```
qqPlot(residuos,
  main = "Gráfico Q-Q", # Título principal
  xlab = "Quantis Teóricos da Distribuição Normal", # Legenda do eixo X
  ylab = "Resíduos do Modelo", # Legenda do eixo Y
  pch = 16,
  lwd = 2, # Um pouco menos espesso que antes para equilibrar
  cex = 1.5 # Um pouco menor para um visual mais limpo
)

## [1] 5 112
```

A Figura 4 ilustra visualmente o alinhamento dos resíduos com uma distribuição normal teórica, evidenciando sua normalidade e a interpretação do teste de **Shapiro-Wilk**.

3.3.2 Homogeneidade de Variâncias (Homocedasticidade)

Testamos a homocedasticidade das variâncias pelo teste de **Fligner-Killeen**.

```
fligner_test_result <- fligner.test(Retorno ~ Acao, data = retornos_long_df_para_teste)
print(fligner_test_result)
```

```
##
##  Fligner-Killeen test of homogeneity of variances
##
## data:  Retorno by Acao
## Fligner-Killeen:med chi-squared = 6.0758, df = 4, p-value = 0.1936
```

O teste de **Fligner-Killeen** realizado retornou um p-valor de 0.1936, não rejeitando a hipótese nula que determina que as variâncias das ações são iguais, o que contrasta com o observado no boxplot da Figura 1,




Figure 4: Gráfico Q-Q para verificação da premissa de normalidade dos resíduos do modelo ANOVA.

que demonstra certa discrepância no tamanho das caixas de cada uma das ações. Para os fins do presente estudo de caso, a premissa foi considerada satisfeita, seguindo o resultado do teste estatístico.

3.3.3 Independência dos Resíduos Testamos a não correlação dos resíduos pelo teste de **Durbin-Watson**.

```
durbin_watson_result <- car::durbinWatsonTest(anova_result)
print(durbin_watson_result)

## lag Autocorrelation D-W Statistic p-value
## 1 0.09164938 1.807413 0.282
## Alternative hypothesis: rho != 0

acf(resíduos, main = "Função de Autocorrelação dos Resíduos da ANOVA")
```

Função de Autocorrelação dos Resíduos da ANOVA




Figure 5: Gráfico da Função de Autocorrelação (ACF) dos resíduos do modelo ANOVA

O teste de **Durbin-Watson** realizado obteve um p-valor de 0.274, não rejeitando a hipótese nula que determina que não há autocorrelação entre os resíduos, ou seja, os resultados do teste evidenciam a não autocorrelação dos dados. No contexto deste estudo de caso, a não autocorrelação sustenta a suposição de independência entre os dados.

Além disso, a Figura 5 mostra que não há correlações significativas nos resíduos na maior parte das diferentes defasagens temporais, suportando a premissa de não autocorrelação e, neste caso, independência. A única defasagem que apresentou correlação marginalmente significativa foi a de 7 meses.

Considerando a natureza dos dados, o esperado caso de fato houvesse autocorrelação é que esta ocorresse em baixas defasagens (1, 2 ou 3 meses), o que indicaria efeitos de curto prazo como “momentum” ou “reversão à

média”. Além disso, a força da correlação é baixa, superando por muito pouco o *threshold* de 5% que, aliado ao efeito esperado da aleatoriedade de que pelo menos 1 a cada 20 observações em séries perfeitamente aleatórias supere a *threshold* de significância de 5%, suporta a conclusão que a significância observada nesta defasagem é fruto de aleatoriedade e não representa autocorrelação real.

3.4 Tamanho do efeito e poder do teste

```
sigma <- 0.01 # max desvio padrao intra grupos
delta <- 0.01 # para um tamanho minimamente relevante de 1 des. pad.

tau <- c(-delta * 4 / 5,
        rep(delta / 5, 4)) # define tau vector

power_result <- power.anova.test(groups = length(desc_stats$Media_Retorno), n = 35,
                                between.var = var(desc_stats$Media_Retorno),
                                within.var = sigma^2)

print(paste("Poder do teste: ", power_result[6]))

## [1] "Poder do teste: 0.986113230883197"
```

A análise de poder estatístico indicou que o teste ANOVA apresentou um poder muito elevado (98.6%), conferindo alta sensibilidade a efeitos que fariam rejeitar a hipótese nula. Podemos concluir assim, que o risco de não detectar uma diferença real entre os grupos é baixo. Dessa forma a probabilidade de cometermos um erro de falso negativo é pequena (1.4%).

4. Conclusões

Com base na análise estatística realizada, foi possível identificar diferenças significativas entre os retornos médios das ações avaliadas. A aplicação do teste ANOVA resultou em rejeição da hipótese nula de igualdade das médias, indicando que pelo menos uma das ações apresenta desempenho médio diferente das demais.

O teste *post hoc* de Tukey HSD revelou que a Ação 2 e a Ação 4 possuem retornos médios estatisticamente menores que a Ação 1, enquanto as demais comparações não apresentaram diferenças significativas, embora a Ação 5 tenha exibido tendência marginal de diferença em relação à Ação 1. Esses resultados corroboram a análise exploratória e o desempenho ajustado ao risco, que já indicavam a Ação 1 como o ativo de melhor rentabilidade e relação risco-retorno no período analisado.

As verificações de normalidade (teste de **Shapiro–Wilk**), homocedasticidade (teste de **Fligner–Killeen**) e independência dos resíduos (teste de **Durbin–Watson**) confirmaram que as premissas do modelo ANOVA foram atendidas, garantindo a validade das conclusões inferenciais. Além disso, a análise de potência do teste evidenciou que o experimento possui alta capacidade de detecção de diferenças reais entre as médias.

Dessa forma, conclui-se que, no horizonte temporal de 36 meses analisado, a Ação 1 se destacou de forma consistente como a alternativa mais vantajosa, apresentando retorno médio superior e melhor desempenho ajustado ao risco. Assim, sob a ótica estatística e considerando o conjunto de evidências apresentadas, a Ação 1 é a opção mais favorável para investimento entre os ativos avaliados neste estudo de caso.

Apendice A - Funções dos integrantes

- Isaac: Responsável pelo projeto e implementação do estudo de caso, esboçar o relatório e discutir a realização do estudo, bem como seus resultados;
- Stéfani: Responsável por discutir a realização do estudo, bem como seus resultados, redigir o texto completo completando e incrementando o esboço;
- Homero: Responsável por discutir a realização do estudo, bem como seus resultados, revisar e complementar o relatório e redigir a versão final.